PHÂN TÍCH BIẾN ĐỘNG GIÁ VÀ HÀNH VI GIAO DỊCH CỔ PHIẾU CỦA CÁC NGÂN HÀNG

Nguyễn Trường Vũ	Đặng Hữu Thọ	Phạm Hùng Quốc Việt	Phạm Minh Ngân
IS403.Q13 University of Information and Technology	IS403.Q13 University of Information and Technology	IS403.Q13 University of Information and Technology	IS403.Q13 University of Information and Technology
23521812@gm.uit.edu.vn	23521517@gm.uit.edu.vn	23521783@gm.uit.edu.vn	23520997@gm.uit.edu.vn

Abstract. Dự báo hành vi và biến động giá cổ phiếu ngân hàng là một bài toán quan trọng trong tài chính định lượng, chịu ảnh hưởng đồng thời từ các yếu tố vĩ mô, động lực thị trường và tâm lý nhà đầu tư. Nghiên cứu này đề xuất một khung thực nghiệm có hệ thống nhằm so sánh hiệu năng dự báo của các mô hình kinh tế lượng, học máy và học sâu trong bối cảnh cổ phiếu ngân hàng Hoa Kỳ. Bộ dữ liệu đa nguồn được sử dụng bao gồm giá cổ phiếu theo tần suất ngày của JPMorgan Chase, Bank of America và Wells Fargo trong giai đoạn 2018–2025, kết hợp với các biến vĩ mô then chốt và chỉ số sentiment từ tin tức tài chính. Tám mô hình thuộc ba nhóm phương pháp được triển khai và đánh giá trên nhiều nhiệm vụ dự báo, với các chiến lược validation phù hợp cho chuỗi thời gian. Kết quả cho thấy không tồn tại một mô hình duy nhất vượt trội trong mọi bối cảnh; hiệu năng dự báo phụ thuộc mạnh vào mục tiêu dự báo và đặc tính dữ liệu. Đặc biệt, vai trò của sentiment chỉ thể hiện rõ trong một số trường hợp cụ thể, nhấn mạnh sự cần thiết của việc tích hợp tín hiệu hành vi một cách thận trọng trong các mô hình dự báo tài chính.

Keywords: Stock price forecasting, Volatility analysis, Banking sector stocks, Machine learning, Deep learning, Investor sentiment

1 Introduction

Dự báo biến động và hành vi giá cổ phiếu là một bài toán trung tâm trong tài chính định lượng, đặc biệt đối với nhóm cổ phiếu ngân hàng — lĩnh vực chịu ảnh hưởng mạnh từ điều kiện kinh tế vĩ mô, biến động thị trường và tâm lý nhà đầu tư. Trong bối cảnh thị trường tài chính hiện đại ngày càng thể hiện tính phi tuyến, sự thay đổi theo chế độ và mức độ nhạy cảm cao với thông tin, hiệu quả của các mô hình tuyến tính truyền thống có xu hướng suy giảm trong nhiều kịch bản thực tế. Trước thực trạng đó, các phương

pháp học máy và học sâu đã thu hút sự quan tâm đáng kể nhờ khả năng khai thác quan hệ phi tuyến và phụ thuộc theo thời gian trong dữ liệu tài chính [1,2].

Trong văn liệu hiện có, các mô hình kinh tế lượng như ARIMAX, SARIMAX và GARCH vẫn được sử dụng rộng rãi nhờ khả năng diễn giải và nền tảng lý thuyết vững chắc, đặc biệt trong phân tích cấu trúc tuyến tính và động lực biến động [3,4]. Song song đó, các phương pháp học máy và học sâu, bao gồm Gradient Boosting, SVM và LSTM, cho thấy tiềm năng vượt trội trong việc xử lý dữ liệu đa chiều và các quan hệ phi tuyến phức tạp [1,2,5]. Tuy nhiên, phần lớn các nghiên cứu vẫn tập trung vào từng nhóm mô hình riêng lẻ hoặc chỉ khai thác dữ liệu giá thuần túy, trong khi các nghiên cứu tích hợp đồng thời dữ liệu giá, biến vĩ mô và sentiment trong một khung so sánh thống nhất giữa các phương pháp khác nhau vẫn còn tương đối hạn chế.

Xuất phát từ những hạn chế trên, nghiên cứu này đề xuất một khung thực nghiệm có hệ thống nhằm phân tích hành vi và biến động giá cổ phiếu ngân hàng Hoa Kỳ trong giai đoạn 2018–2025. Nghiên cứu tập trung vào ba ngân hàng lớn — JPMorgan Chase (JPM), Bank of America (BAC) và Wells Fargo (WFC) — sử dụng bộ dữ liệu đa nguồn bao gồm giá cổ phiếu theo tần suất ngày, các yếu tố vĩ mô then chốt (VIX, SPX500 và Federal Funds Rate) và chỉ số sentiment được xây dựng từ tin tức tài chính [6,7]. Trên cơ sở đó, tám mô hình thuộc ba nhóm phương pháp chính — kinh tế lượng, học máy và học sâu — được triển khai và đánh giá trên nhiều nhiệm vụ dự báo, bao gồm dự báo giá, dự báo biến động và phân loại hướng biến động giá, với các chiến lược validation được thiết kế phù hợp cho từng lớp mô hình.

Những đóng góp chính của nghiên cứu bao gồm: cung cấp một so sánh toàn diện và nhất quán giữa các mô hình kinh tế lượng, học máy và học sâu trong bối cảnh cổ phiếu ngân hàng, làm rõ vai trò và giới hạn của dữ liệu sentiment trong dự báo tài chính thông qua so sánh các cấu hình mô hình có và không tích hợp sentiment và nhấn mạnh sự phụ thuộc của hiệu năng dự báo vào mục tiêu dự báo và đặc tính cấu trúc của từng cổ phiếu, thay vì độ phức tạp mô hình đơn thuần.

Phần còn lại của bài báo được tổ chức như sau. Phần tiếp theo trình bày chi tiết phương pháp nghiên cứu và khung thực nghiệm. Kết quả thực nghiệm và phân tích được trình bày sau đó, tiếp theo là phần thảo luận các phát hiện chính. Cuối cùng, bài báo khép lại bằng phần kết luận và các hướng nghiên cứu trong tương lai.

2 Related Work

2.1 Econometric Models for Stock Price and Volatility Forecasting

Các mô hình kinh tế lượng truyền thống đóng vai trò nền tảng trong phân tích và dự báo chuỗi thời gian tài chính nhờ khả năng diễn giải rõ ràng và cơ sở lý thuyết vững chắc. Các mô hình thuộc họ ARIMA và các biến thể mở rộng như ARIMAX và SARIMAX đã được sử dụng rộng rãi để dự báo giá cổ phiếu, trong đó các biến ngoại sinh cho phép mô hình phản ánh tác động của các yếu tố kinh tế vĩ mô và thị trường. Việc tích hợp các chỉ số như lãi suất, chỉ số thị trường chung hoặc các biến tài chính tổng hợp được chứng minh là giúp cải thiện hiệu năng dự báo trong một số bối cảnh nhất định [8].

Song song đó, các mô hình GARCH và các biến thể của chúng được phát triển nhằm mô hình hóa động lực phương sai có điều kiện và hiện tượng volatility clustering đặc trưng của thị trường tài chính. Các nghiên cứu trước cho thấy GARCH đặc biệt hiệu quả trong phân tích và dự báo biến động, đóng vai trò quan trọng trong quản trị rủi ro và định giá tài sản [3]. Tuy nhiên, các mô hình kinh tế lượng nhìn chung bị giới hạn bởi giả định tuyến tính, tính dừng và cấu trúc tham số cố định, khiến chúng gặp khó khăn trong việc thích nghi với các giai đoạn thị trường biến động mạnh hoặc khi xuất hiện các quan hệ phi tuyến phức tạp.

2.2 Machine Learning Approaches in Financial Markets

Nhằm khắc phục các hạn chế của mô hình kinh tế lượng, các phương pháp học máy đã được áp dụng ngày càng rộng rãi trong dự báo tài chính. Các mô hình tuyến tính như Logistic Regression thường được sử dụng như baseline cho bài toán phân loại hướng biến động giá, trong khi các mô hình phi tuyến như Support Vector Machine (SVM) cho thấy khả năng học các ranh giới quyết định phức tạp hơn trong không gian đặc trưng. Một số nghiên cứu chỉ ra rằng SVM có thể cải thiện độ chính xác so với các mô hình tuyến tính, đặc biệt khi dữ liệu được tiền xử lý phù hợp và xử lý tốt hiện tượng mất cân bằng lớp [1].

Các mô hình dựa trên cây quyết định, bao gồm Random Forest và Gradient Boosting Tree, được đánh giá cao nhờ khả năng mô hình hóa quan hệ phi tuyến và tương tác phức tạp giữa các biến đầu vào [1,5]. Trong bối cảnh tài chính, các phương pháp boosting như XGBoost và LightGBM đã được chứng minh là hiệu quả trong dự báo biến động và lợi suất ngắn hạn, đồng thời cho phép đánh giá tầm quan trọng của đặc trưng thông qua các công cụ giải thích như SHAP. Tuy vậy, hiệu năng của các mô hình học máy phụ thuộc mạnh vào chiến lược xây dựng đặc trưng, phương pháp chia dữ liệu theo thời gian và cơ chế kiểm soát overfitting, khiến kết quả giữa các nghiên cứu đôi khi thiếu nhất quán.

2.3 Deep Learning for Financial Time-Series Prediction

Trong thập kỷ gần đây, các mô hình học sâu, đặc biệt là mạng nơ-ron hồi quy (Recurrent Neural Networks), đã trở thành hướng tiếp cận phổ biến trong dự báo chuỗi thời gian tài chính. Long Short-Term Memory (LSTM) được thiết kế nhằm giải quyết vấn đề mất gradient và học các phụ thuộc dài hạn trong chuỗi thời gian, qua đó cho thấy hiệu năng vượt trội trong nhiều bài toán dự báo giá và lợi suất. Các nghiên cứu gần đây cho thấy LSTM có khả năng khai thác hiệu quả các mẫu động lực phức tạp và sự phụ thuộc theo thời gian mà các mô hình truyền thống khó nắm bắt [2,9].

Gated Recurrent Unit (GRU) được đề xuất như một biến thể gọn nhẹ hơn của LSTM, với số lượng tham số ít hơn và tốc độ hội tụ nhanh hơn trong nhiều kịch bản thực nghiệm. Trong lĩnh vực tài chính, GRU thường được sử dụng cho dự báo ngắn hạn hoặc khi dữ liệu hạn chế, giúp giảm nguy cơ overfitting. Mặc dù các mô hình học sâu cho thấy tiềm năng lớn, chúng cũng đối mặt với các thách thức đáng kể, bao gồm khả năng diễn giải hạn chế, độ nhạy cao với siêu tham số và nguy cơ overfitting khi dữ liệu không đủ phong phú hoặc có mức độ nhiễu cao.

2.4 Incorporating Macroeconomic Variables and Sentiment

Bên cạnh dữ liệu giá, nhiều nghiên cứu đã chỉ ra vai trò quan trọng của các yếu tố kinh tế vĩ mô trong việc giải thích và dự báo biến động thị trường. Các chỉ số như VIX, đại diện cho mức độ bất ổn thị trường, chỉ số thị trường chung như S&P 500, hay lãi suất điều hành của ngân hàng trung ương thường được sử dụng như các biến ngoại sinh trong các mô hình dự báo tài chính [4,7]. Việc tích hợp các biến này giúp mô hình phản ánh tốt hơn bối cảnh kinh tế tổng thể và phản ứng của thị trường trước các cú sốc vĩ mô.

Song song đó, dữ liệu sentiment được khai thác từ tin tức tài chính hoặc mạng xã hội ngày càng được quan tâm như một nguồn thông tin bổ sung nhằm phản ánh yếu tố hành vi và tâm lý nhà đầu tư [6]. Một số nghiên cứu cho thấy sentiment có thể cải thiện khả năng dự báo, đặc biệt trong các giai đoạn thị trường biến động mạnh hoặc đối với các tài sản nhạy cảm với thông tin. Tuy nhiên, các kết quả thực nghiệm về hiệu quả của sentiment vẫn còn trái chiều. Nhiều công trình chỉ ra rằng sentiment không phải lúc nào cũng mang lại cải thiện ổn định, thậm chí có thể đưa thêm nhiễu vào mô hình nếu không được xử lý và tích hợp phù hợp [6,7].

2.5 Summary and Research Gap

Tổng hợp văn liệu cho thấy không tồn tại một phương pháp duy nhất vượt trội trong mọi bối cảnh dự báo tài chính, như đã được ghi nhận trong nhiều nghiên cứu tổng quan gần đây. Các mô hình kinh tế lượng cung cấp khả năng diễn giải và phân tích cấu trúc, trong khi các phương pháp học máy và học sâu cho thấy ưu thế trong việc mô hình hóa các quan hệ phi tuyến và phụ thuộc theo thời gian. Tuy nhiên, phần lớn các nghiên cứu hiện tại vẫn tập trung vào từng nhóm phương pháp riêng lẻ, thiếu một khung so sánh thống nhất giữa các mô hình với các mục tiêu dự báo khác nhau, đặc biệt trong bối cảnh tích hợp dữ liệu đa nguồn và áp dụng các chiến lược validation phù hợp cho chuỗi thời gian.

Những hạn chế này tạo động lực cho nghiên cứu hiện tại, trong đó đề xuất một khung thực nghiệm có hệ thống nhằm so sánh các mô hình kinh tế lượng, học máy và học sâu trên dữ liệu cổ phiếu ngân hàng đa chiều.

3 Methodology

3.1 Data Sources

Nghiên cứu sử dụng bộ dữ liệu đa nguồn bao gồm dữ liệu tài chính và dữ liệu vĩ mô trong giai đoạn từ 01/01/2018 đến 11/11/2025. Tất cả dữ liệu giá đều được thu thập theo tần suất ngày từ Yahoo Finance thông qua Python API (yfinance) và được đồng bộ hóa về cùng một mốc thời gian. Ba mã cổ phiếu ngân hàng lớn của Hoa Kỳ — JPMorgan Chase (JPM), Bank of America (BAC) và Wells Fargo (WFC) — được thu thập với các trường Open, High, Low, Close và Volume. Các biến này đóng vai trò cơ sở để xây dựng log-return, rolling volatility cùng nhiều đặc trưng kỹ thuật khác.

Dữ liệu vĩ mô bao gồm ba yếu tố then chốt, bao gồm chỉ số VIX phản ánh mức độ bất ổn thị trường, chỉ số SPX500 đại diện cho xu hướng thị trường chung, và FED Funds Rate thể hiện điều kiện chính sách tiền tệ. Các biến này được tích hợp vào mô hình như các tín hiệu ngoại sinh nhằm đánh giá mức độ ảnh hưởng của bối cảnh kinh tế vĩ mô lên biến động cổ phiếu ngân hàng.

Dữ liệu cảm xúc (sentiment) được thu thập theo tần suất ngày từ các nguồn tin tức tài chính và chỉ số sentiment được xây dựng bằng phương pháp từ điển có trọng số, phản ánh mức độ tích cực hoặc tiêu cực của từng ngày. Do tính chất không liên tục của tin tức, những ngày không có dữ liệu được xử lý bằng phương pháp zero-imputation. Chỉ số sentiment ban đầu có biên độ giá trị rộng và được đưa vào quy trình tiền xử lý tùy theo đặc thù của từng mô hình.

Đối với các mô hình học máy truyền thống (Logistic Regression, SVM và Gradient Boosting Tree), dữ liệu được xử lý bằng cách chuẩn hóa cột Date thành index thời gian, xử lý missing values, và kết hợp dữ liệu giá, dữ liệu vĩ mô và sentiment để xây dựng bộ đặc trưng thống nhất cho từng cổ phiếu.

Đối với các mô hình học sâu (LSTM và GRU), dữ liệu được tải trực tiếp từ các file nguồn, hợp nhất theo timestamp, và chuyển đổi sang dạng tensor chuỗi thời gian với cấu trúc sliding window nhằm phục vụ cho việc học quan hệ phụ thuộc theo thời gian.

Sau khi thu thập, toàn bộ dữ liệu được đồng bộ hóa về cùng một timeline và chuẩn bị cho các bước tiền xử lý chuyên biệt theo từng nhóm mô hình.

3.2 Data Preprocessing

Tùy theo bản chất của từng nhóm mô hình, quy trình tiền xử lý dữ liệu được thiết kế theo hướng bán thống nhất (semi-unified preprocessing) nhằm đảm bảo vừa tránh rò rỉ thông tin (data leakage), vừa phù hợp với giả định toán học của từng kiến trúc mô hình.

Đối với các mô hình dự báo giá và lợi suất, log-return được tính theo công thức:

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right), \tag{1}$$

nhằm ổn định phương sai của chuỗi thời gian và đưa dữ liệu về dạng gần Gaussian hơn, phù hợp với các giả định của mô hình kinh tế lượng và học máy.

Đối với các mô hình dự báo biến động, realized volatility được ước lượng từ lợi suất theo các cửa sổ trượt khác nhau, phản ánh mức độ dao động nội tại của thị trường.

Các biến trễ (lagged features) được xây dựng cho lợi suất và biến động nhằm mô hình hóa tính phụ thuộc theo thời gian. Trong khi đó, các biến vĩ mô (SPX500, VIX, Fed Funds Rate) và sentiment được đồng bộ hóa theo tần suất ngày và xử lý missing values bằng forward-fill; riêng sentiment được zero-imputation cho những ngày không có tin tức.

Chiến lược chuẩn hóa được áp dụng khác nhau theo nhóm mô hình. Các mô hình tuyến tính và Logistic Regression sử dụng StandardScaler để đưa dữ liệu về phân phối chuẩn. Các mô hình dựa trên cây quyết định (Gradient Boosting Tree) không yêu cầu

chuẩn hóa. Các mô hình học sâu (LSTM, GRU) sử dụng MinMaxScaler trong khoảng [0,1], trong đó scaler chỉ được fit trên tập huấn luyện nhằm tránh rò rỉ dữ liệu.

Quá trình chuẩn hóa được thực hiện theo công thức:

$$X_{scaled} = \frac{X - X_{min}}{X_{max} - X_{min}}, \quad (2)$$

Trong đó X_{min} và X_{max} là giá trị nhỏ nhất và lớn nhất được tính toán chỉ trên tập huấn luyện nhằm đảm bảo tính toàn vẹn của dữ liệu và tránh hiện tượng rò rỉ thông tin (data leakage) sang tập kiểm thử.

3.3 Modeling Framework

Nghiên cứu triển khai 8 mô hình dự báo, được chia thành ba nhóm chính: mô hình kinh tế lượng, mô hình học máy, và mô hình học sâu, nhằm phân tích toàn diện hành vi giá và biến động của cổ phiếu ngân hàng. Cụ thể, các mô hình bao gồm ARIMAX, SARIMAX, GARCH(1,1), Gradient Boosting Tree (LightGBM), Logistic Regression, SVM, GRU và LSTM (với hai cấu hình có và không tích hợp sentiment).

Econometric Models

. Nhóm mô hình kinh tế lượng bao gồm ARIMAX, SARIMAX và GARCH(1,1).

ARIMAX và SARIMAX được sử dụng cho bài toán dự báo giá đóng cửa (Close price), trong đó các biến ngoại sinh được tích hợp nhằm mở rộng mô hình ARIMA truyền thống.

Mô hình ARIMAX được thiết lập như một sự mở rộng của mô hình hồi quy tuyến tính với sai số có cấu trúc ARIMA. Phương trình dự báo tại thời điểm t được biểu diễn như sau:

$$y_t = \mu + \sum_{j=1}^{k} \beta_j X_{tj} + \mu_t, \quad (3)$$

Trong đó phần nhiễu ut tuân theo cấu trúc ARIMA(p,q):

$$\mu_t = \phi_1 \mu_{t-1} + \cdots + \phi_p \mu_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}, \quad (4)$$

Giải thích tham số & Cấu hình :

- Biến phụ thuộc (yt): Giá đóng cửa (Close price) đã được chuyển đổi Logarithm (np.log1p) để ổn định phương sai trước khi huấn luyện.
- Biến ngoại sinh (Xt): Bao gồm các chỉ số vĩ mô (SPX500, FED_RATE) và Sentiment.
- Cơ chế huấn luyện: Sử dụng thư viện pmdarima.auto_arima với thiết lập seasonal=False để tự động tìm kiếm bộ tham số (p,d,q) tối ưu dựa trên tiêu chuẩn thông tin AIC.
- Chiến lược dự báo: Rolling Forecast (Cửa sổ trượt) với window_size=500. Mô hình được tái huấn luyện (re-fit) liên tục sau mỗi bước thời gian để cập nhật thông tin mới nhất, phản ánh sát thực tế giao dịch.

Kết quả tối ưu hóa từ thuật toán Auto-ARIMA xác định cấu hình (1, 1, 1) là phù hợp nhất cho mô hình ARIMAX. Điều này phản ánh đặc thù của chuỗi giá cổ phiếu ngân hàng: có xu hướng (cần sai phân d=1), phụ thuộc mạnh vào phiên liền trước (AR=1) và phản ứng tức thời với các cú sốc ngắn hạn (MA=1), phù hợp với giả thuyết thị trường hiệu quả dạng yếu.

SARIMAX được triển khai dưới dạng static multi-step forecasting, cho phép đánh giá khả năng dự báo toàn bộ giai đoạn kiểm thử trong một lần huấn luyện.

Về mặt toán học, mô hình SARIMAX được biểu diễn tổng quát như sau:

$$\phi_p(L)\widetilde{\phi_P}(L^s)\Delta^d\Delta_s^D(y_t - X_t\beta) = \theta_q(L)\widetilde{\theta_Q}(L^s)\varepsilon_t, \quad (5)$$

Trong đó:

- y_t là giá trị chuỗi thời gian cần dự báo và X_t là thành phần hồi quy của các biến ngoại sinh (Sentiment, VIX, FED Rate).
- Δ_d và Δ_s^D lần lượt là toán tử sai phân thường và sai phân mùa vụ để đảm bảo tính dừng.
- Bộ tham số (p, q) và (P, Q) đại diện cho bậc tự hồi quy và trung bình trượt của phần phi mùa vụ và mùa vụ.

Cấu hình mô hình: Thay vì sử dụng các thuật toán tự động (như Auto-ARIMA), nghiên cứu áp dụng quy trình xác định tham số dựa trên kiểm định thống kê:

1. Tính dừng: Kiểm định Augmented Dickey-Fuller (ADF) xác định bậc sai phân d.
2. Bậc mô hình: Phân tích biểu đồ Tự tương quan (ACF) và Tự tương quan riêng phần (PACF) để xác định p, q và P, Q.
3. Cơ chế dự báo: Sử dụng Static Multi-step Forecast cho tập kiểm thử. Tại mỗi bước t+1, mô hình sử dụng giá trị thực tế của các biến trễ tại thời điểm t, giúp giảm thiểu sai số tích lũy.

Mô hình được thiết lập với order=(5,1,1) nhằm phản ánh chu kỳ giao dịch tuần (p=5 ngày làm việc) và seasonal_order=(3,1,2,22) tương ứng với chu kỳ tháng (s=22 ngày giao dịch). Cấu hình này, được tối ưu hóa dựa trên tiêu chuẩn AIC/BIC, cho phép nắm bắt đồng thời động lượng ngắn hạn và xu hướng mùa vụ trung hạn (theo quý với P=3) đặc trưng của chuỗi dữ liệu tài chính.

Mô hình GARCH(1,1) tập trung vào việc dự báo conditional volatility của lợi suất log hằng ngày, nhằm nắm bắt hiện tượng volatility clustering đặc trưng của thị trường tài chính.

Mô hình GARCH(1,1) được định nghĩa bởi hai phương trình: phương trình trung bình $r_t = \mu + \epsilon_t$ và phương trình phương sai có điều kiện:

$$\sigma_t^2 = \omega + \alpha\varepsilon_{t-1}^2 + \beta\sigma_{t-1}^2, \quad (6)$$

Giải thích tham số:

- α (ARCH term): Đo lường phản ứng ngắn hạn của biến động đối với các cú sốc thông tin mới.

- β (GARCH term): Đo lường tính bền vững (persistence) của biến động theo thời gian.
- Tổng $\alpha + \beta < 1$ đảm bảo tính dừng, nghĩa là các cú sốc biến động sẽ dần suy giảm.

Machine Learning Models

. Nhóm học máy bao gồm Gradient Boosting Tree (LightGBM), Logistic Regression và SVM.

Gradient Boosting Tree, được triển khai bằng LightGBM, tập trung vào bài toán dự báo realized volatility ngày kế tiếp, với cơ chế early stopping nhằm kiểm soát overfitting.

LightGBM xây dựng mô hình dự báo dưới dạng tổng hợp (ensemble) của K cây quyết định yếu (weak learners). Tại bước lặp m, mô hình học một cây mới $f_m(x)$ để tối thiểu hóa hàm mục tiêu bao gồm sai số dự báo và thành phần điều chuẩn Ω:

$$\widehat{y_i} = \sum_{k=1}^{K} f_k(x_i), \quad f_k \in \mathcal{F}, \tag{7}$$

$$\mathcal{L}^{(m)} = \sum_{i=1}^{n} L\left(y_i, \widehat{y_i^{(m-1)}} + f_m(x_i)\right) + \Omega(f_m), \tag{8}$$

Giải thích tham số & Cấu hình :

- **Objective:** Regression (Hồi quy) với hàm mất mát L2 (Mean Squared Error) cho bài toán dự báo biến động thực tế (Realized Volatility).
- **Boosting Type:** GBDT (Gradient Boosting Decision Tree).
- Chiến lược chống Overfitting: Sử dụng cơ chế Early Stopping (dừng sớm) dựa trên tập Validation. Nếu sai số trên tập Validation không giảm sau một số vòng lặp nhất định (stopping_rounds), quá trình huấn luyện sẽ dừng lại. * SHAP Values: Sử dụng thư viện SHAP để giải thích mức độ đóng góp (feature importance) của các biến đầu vào đối với kết quả dự báo.

Logistic Regression và SVM được sử dụng cho bài toán phân loại hướng biến động giá (up/down), trong đó biến mục tiêu được xác định dựa trên log-return ngày kế tiếp. Cụ thể, nhãn được gán bằng 1 nếu log-return dương và 0 nếu log-return âm hoặc bằng 0.

Về mặt toán học, Logistic Regression mô hình hóa xác suất xảy ra sự kiện tăng giá tại thời điểm t+1 thông qua hàm logistic:

$$P(y_{t+1} = 1 \mid x_t) = \sigma(w^{\top x_t} + b), \tag{9}$$

Trong đó, SVM được mở rộng với SMOTE để xử lý mất cân bằng lớp trong dữ liệu huấn luyện mở rộng khả năng mô hình hóa bằng cách sử dụng kernel phi tuyến RBF (Radial Basis Function) nhằm học các ranh giới phân lớp phức tạp hơn trong không gian đặc trưng.

Hàm quyết định của SVM được biểu diễn dưới dạng:

$$f(x) = \sum_{i=1}^{N} \alpha_i y_i K(x_i, x) + b, \tag{10}$$

Deep Learning Models

. Nhóm học sâu bao gồm GRU và LSTM.

GRU được xây dựng cho bài toán dự báo giá đóng cửa ngày kế tiếp (next-day price regression), trong đó dữ liệu đầu vào được biểu diễn dưới dạng chuỗi thời gian với cửa sổ trượt cố định, kết hợp các biến vĩ mô và sentiment nhằm học các quan hệ phụ thuộc theo thời gian ngắn và trung hạn.

Tại mỗi thời điểm ttt, GRU cập nhật trạng thái ẩn hth_tht thông qua hai cổng chính: cổng cập nhật (update gate) và cổng đặt lại (reset gate):

$$z_t = \sigma(W_z x_t + U_z h_{t-1}), \tag{11}$$

$$r_t = \sigma(W_r x_t + U_r h_{t-1}), \tag{12}$$

$$\widetilde{h_t} = \tanh\big(W_h x_t + U_h(r_t \odot h_{t-1})\big), \tag{13}$$

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \widetilde{h_t}, \tag{14}$$

Cấu trúc này cho phép GRU học được cả phụ thuộc ngắn hạn và trung hạn, đồng thời giảm số lượng tham số so với LSTM.

LSTM được triển khai như một họ mô hình thống nhất, bao gồm các biến thể có và không tích hợp sentiment. Mô hình LSTM dự báo giá đóng cửa trực tiếp (price-level forecasting) theo cơ chế rolling one-step-ahead forecast, cho phép đánh giá ảnh hưởng của sentiment thông qua so sánh hiệu năng giữa các cấu hình có và không sentiment.

Mạng LSTM giải quyết vấn đề phụ thuộc dài hạn thông qua cơ chế cổng (gates). Tại mỗi bước thời gian t, trạng thái tế bào C_t và trạng thái ẩn h_t được cập nhật như sau:

$$f_t = \sigma\big(W_f \cdot [h_{t-1}, x_t] + b_f\big), \tag{15}$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i), \tag{16}$$

$$C_t = f_t * C_{t-1} + i_t * \tanh(W_C \cdot [h_{t-1}, x_t] + b_C), \tag{17}$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o), \tag{18}$$

$$h_t = o_t * \tanh(C_t), \tag{19}$$

Thiết lập kiến trúc:

- Sliding Window: Đầu vào là chuỗi thời gian có độ dài $N=22$ ngày (tương ứng 1 tháng giao dịch).
- Gates: Sử dụng hàm kích hoạt Sigmoid (σ) để điều tiết luồng thông tin, giúp mô hình học được cách lọc nhiễu từ dữ liệu sentiment và giá quá khứ.

3.4 Reproducibility and Training Configuration

Toàn bộ thí nghiệm trong nghiên cứu được triển khai bằng Python 3.9, sử dụng các thư viện chính bao gồm NumPy, Pandas, scikit-learn, statsmodels, LightGBM và TensorFlow/Keras. Các mô hình được huấn luyện và đánh giá trong cùng một môi trường thực nghiệm nhằm đảm bảo tính nhất quán giữa các phương pháp. Để tăng cường khả năng

tái lập kết quả, random seed được cố định ở giá trị 42 cho NumPy, scikit-learn và TensorFlow trong toàn bộ các thí nghiệm học máy và học sâu.

Các cấu hình huấn luyện và siêu tham số được thiết lập phù hợp với đặc thù của từng nhóm mô hình, đồng thời bám sát cấu hình được sử dụng trong code thực nghiệm.

Đối với các mô hình kinh tế lượng như ARIMAX và SARIMAX, bộ tham số (p,d,q) và (P,D,Q,s) được xác định thông qua phân tích ACF/PACF, kết hợp với các biến ngoại sinh vĩ mô bao gồm chỉ số SPX500 và FED Funds Rate; sentiment được đưa vào như một biến ngoại sinh trong các cấu hình có xét đến yếu tố hành vi thị trường.

Mô hình GARCH(1,1) được ước lượng bằng phương pháp Quasi-Maximum Likelihood nhằm mô hình hóa động lực phương sai có điều kiện của lợi suất log.

Trong nhóm mô hình học máy, Gradient Boosting Tree được triển khai bằng LightGBM với learning rate nhỏ và cơ chế early stopping dựa trên tập validation theo thứ tự thời gian. Logistic Regression và SVM được sử dụng cho bài toán phân loại hướng biến động giá; trong đó Logistic Regression áp dụng chuẩn hóa đặc trưng bằng StandardScaler, còn SVM sử dụng kernel RBF và áp dụng SMOTE trên tập huấn luyện nhằm xử lý hiện tượng mất cân bằng lớp.

Các mô hình học sâu bao gồm GRU và LSTM được huấn luyện bằng optimizer Adam với batch size 32 và số epoch tối đa khoảng 50, kết hợp cơ chế early stopping. Dữ liệu đầu vào được chuyển đổi sang dạng chuỗi thời gian thông qua sliding window có độ dài 22 ngày và được chuẩn hóa bằng MinMaxScaler, trong đó scaler chỉ được fit trên tập huấn luyện.

3.5 Validation Strategies

Do sự khác biệt về kiến trúc và mục tiêu dự báo, nghiên cứu này áp dụng nhiều chiến lược validation khác nhau, phù hợp với từng nhóm mô hình.

Các mô hình ARIMAX, SARIMAX, Logistic Regression và SVM sử dụng hold-out time-series split, trong đó dữ liệu được chia theo thứ tự thời gian với tỷ lệ 80% train và 20% test, không sử dụng tập validation riêng.

Mô hình Gradient Boosting Tree (LightGBM) sử dụng chronological split có validation, với tỷ lệ 70% train – 15% validation – 15% test, trong đó tập validation được dùng cho cơ chế early stopping.

Mô hình GARCH(1,1) được đánh giá bằng rolling / expanding-window forecast, với nhiều cấu hình chia dữ liệu khác nhau (70–15–15, 80–10–10 và 90–5–5) nhằm kiểm tra độ ổn định của mô hình trong các kịch bản thời gian khác nhau.

Mô hình GRU sử dụng chronological hold-out với validation riêng, với tỷ lệ 80% train – 10% validation – 10% test, phục vụ cho việc theo dõi quá trình huấn luyện.

Mô hình LSTM sử dụng chronological hold-out kết hợp rolling one-step-ahead forecast, với tỷ lệ 80% train – 10% validation – 10% test, nhằm đánh giá khả năng dự báo trong bối cảnh học tuần tự theo thời gian.

Riêng SVM, mặc dù sử dụng hold-out time-series split với tỷ lệ 80% train và 20% test, kỹ thuật SMOTE được áp dụng chỉ trên tập huấn luyện nhằm xử lý hiện tượng mất cân bằng lớp [10].

Table 1. Bảng tổng hợp

Model	Prediction task	Validation strategy	Train / Val / Test
ARIMAX(1,1,1)	Regression – Dự báo giá	Hold-out time-series split (static multi-step forecast)	80% / 0% / 20%
SARIMAX (5, 1, 1), (3, 1, 2, 22)	Regression – Dự báo giá	Hold-out time-series split (static forecast, seasonal)	80% / 0% / 20%
GARCH (1,1)	Volatility regression	Rolling / expanding-window forecast	70–15–15 / 80–10–10 / 90–5–5
Gradient Boosting Tree (LightGBM)	Regression – Dự báo next-day realized volatility	Chronological split + validation (early stopping)	70% / 15% / 15%
Logistic Regression	Binary classification – Dự báo hướng giá	Hold-out time-series split	80% / 0% / 20%
SVM	Binary classification – Dự báo hướng giá	Hold-out time-series split + SMOTE (train only)	80% / 0% / 20%
GRU	Regression – Dự báo next-day price	Chronological hold-out + validation	80% / 10% / 10%
LSTM + Sentiment	Regression – Dự báo next-day price	Chronological hold-out + rolling forecast	80% / 10% / 10%
LSTM (No Sentiment)	Regression – Dự báo next-day price	Chronological hold-out + rolling forecast	80% / 10% / 10%

3.6 Evaluation Metrics

Các mô hình hồi quy bao gồm ARIMAX, SARIMAX, GARCH(1,1), Gradient Boosting Tree, GRU và LSTM được đánh giá bằng các thước đo RMSE, MAE và MAPE, nhằm phản ánh sai số dự báo ở cả mức độ tuyệt đối và tương đối.

Các mô hình phân loại bao gồm Logistic Regression và SVM được đánh giá bằng Accuracy, Precision, Recall và F1-score, nhằm đánh giá khả năng dự báo hướng biến động giá.

Đối với các mô hình học sâu, quá trình huấn luyện còn được theo dõi thông qua training loss và validation loss, hỗ trợ cơ chế early stopping và kiểm soát hiện tượng overfitting.

4 Results

4.1 Experimental Setup Overview

Các mô hình trong nghiên cứu được đánh giá trên bộ dữ liệu tổng hợp theo tần suất ngày, bao gồm giá cổ phiếu của ba ngân hàng Hoa Kỳ (JPM, BAC và WFC), các biến vĩ mô (SPX500, VIX và Federal Funds Rate) cùng với chỉ số sentiment. Toàn bộ quy trình xử lý dữ liệu, xây dựng đặc trưng và chia tập dữ liệu được thực hiện đúng theo phương pháp luận trình bày trong Phần 3, nhằm đảm bảo tính nhất quán và tránh hiện tượng rò rỉ thông tin theo thời gian.

Các mô hình hồi quy được đánh giá dựa trên khả năng dự báo giá đóng cửa ngày kế tiếp hoặc biến động thực tế (realized volatility), trong khi các mô hình phân loại tập trung vào dự báo hướng biến động giá (tăng/giảm). Việc so sánh kết quả được thực hiện chỉ giữa các mô hình có cùng mục tiêu dự báo và chiến lược huấn luyện, nhằm đảm bảo tính hợp lý về mặt phương pháp.

Trên cơ sở đó, các kết quả được trình bày theo từng nhóm mô hình và từng cặp so sánh cụ thể, nhằm làm rõ vai trò và giới hạn của mỗi phương pháp trong các bối cảnh dự báo khác nhau

4.2 Results of Econometric Models

So sánh ARIMAX và SARIMAX

. ARIMAX và SARIMAX được sử dụng cho bài toán dự báo giá đóng cửa, với các biến vĩ mô và sentiment đóng vai trò biến ngoại sinh. ARIMAX mở rộng mô hình ARIMA truyền thống bằng cách tích hợp các tín hiệu thị trường bên ngoài, cho phép mô hình phản ứng với các cú sốc vĩ mô ngắn hạn. Tuy nhiên, do không mô hình hóa rõ ràng thành phần mùa vụ, hiệu năng của ARIMAX có xu hướng suy giảm trong các giai đoạn thị trường biến động mạnh

Ngược lại, SARIMAX cho thấy hiệu năng ổn định và nhất quán hơn trên cả ba cổ phiếu. Việc bổ sung thành phần mùa vụ và cơ chế dự báo tĩnh đa bước (static multi-step forecast) giúp SARIMAX duy trì sai số thấp hơn ARIMAX trong giai đoạn kiểm thử, đặc biệt đối với BAC và WFC — hai mã có xu hướng dao động theo chu kỳ rõ rệt hơn.

Table 2. RMSE và MAPE của ARIMAX và SARIMAX cho JPM, BAC, WFC (Test set)

Model	Stock	RMSE (Test)	MAPE (Test)
ARIMAX (1,1,1)	JPM	43.06	13.50%
	BAC	1.32	2.40%
	WFC	4.94	6.10%
SARIMAX (5, 1, 1),(3, 1, 2, 22)	JPM	45.95	14.47%
	BAC	3.15	5.96%
	WFC	8.66	10.28%

SARIMAX ARIMAX

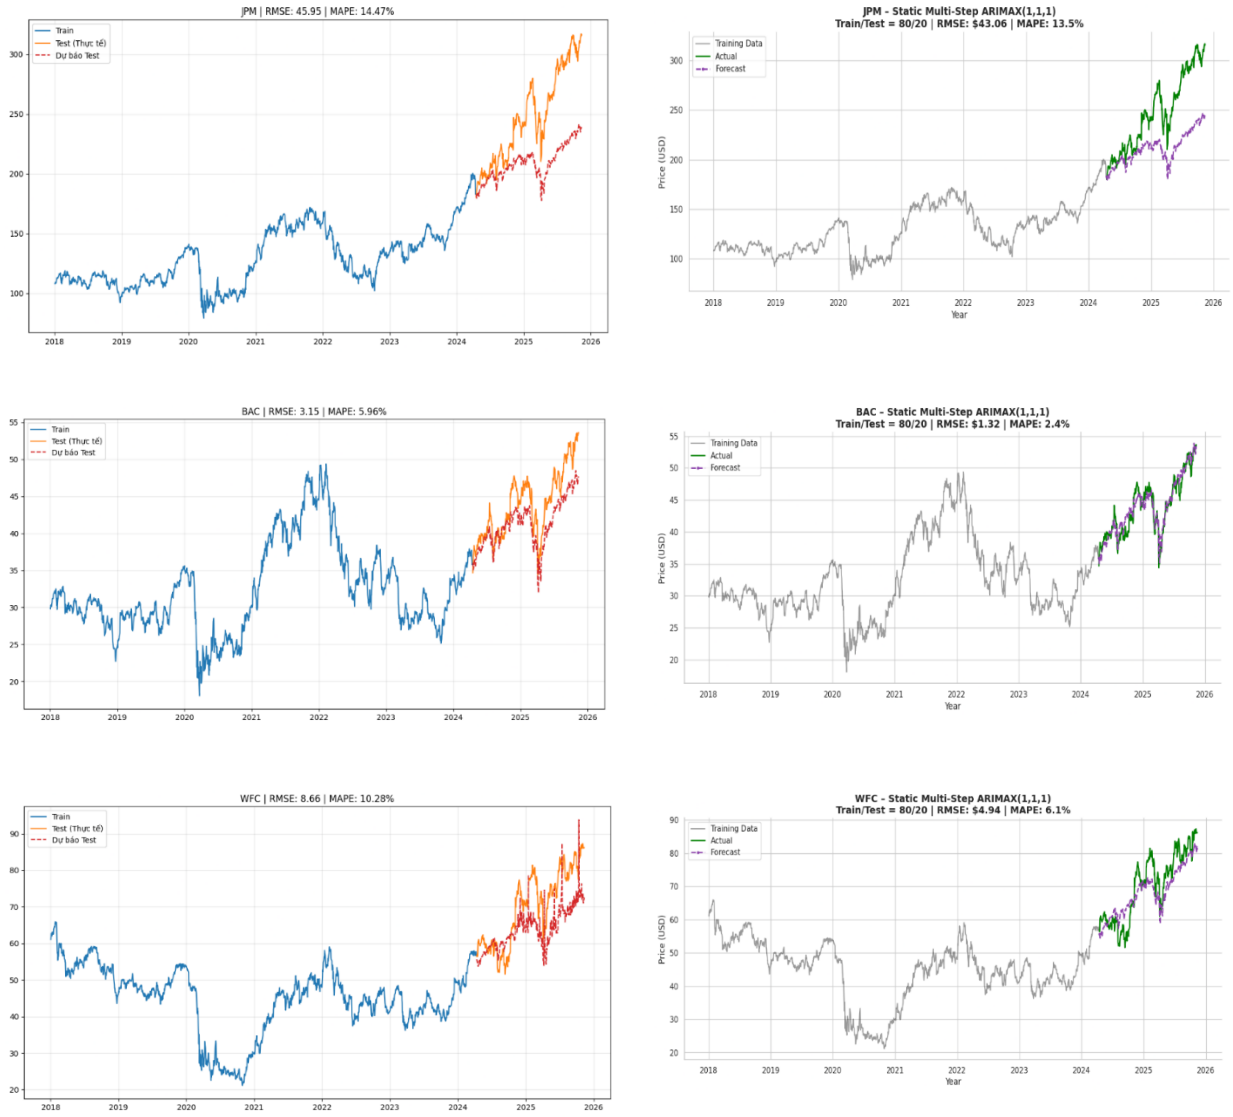

Fig. 1. Actual vs Forecast (ARIMAX và SARIMAX) cho từng cổ phiếu

Phân tích phần dư cho thấy SARIMAX giảm đáng kể hiện tượng tự tương quan so với ARIMAX, củng cố vai trò của thành phần mùa vụ trong mô hình hóa chuỗi thời gian giá cổ phiếu ngân hàng.

Mô hình bổ sung: GARCH(1,1)

. GARCH(1,1) được triển khai nhằm dự báo biến động có điều kiện của lợi suất log, thay vì dự báo mức giá. Do khác biệt về mục tiêu dự báo, GARCH(1,1) không được so sánh trực tiếp với các mô hình dự báo giá.

Kết quả cho thấy GARCH(1,1) nắm bắt tốt hiện tượng volatility clustering đặc trưng của thị trường tài chính, đặc biệt trong các giai đoạn bất ổn. Điều này xác nhận vai trò của GARCH như một công cụ phân tích biến động bổ trợ, thay vì một mô hình dự báo giá cạnh tranh với ARIMAX hay SARIMAX.

Do đó, GARCH(1,1) được xem như một mô hình tham chiếu quan trọng cho phân tích động lực biến động, thay vì một công cụ cạnh tranh trực tiếp trong dự báo giá ngắn hạn.

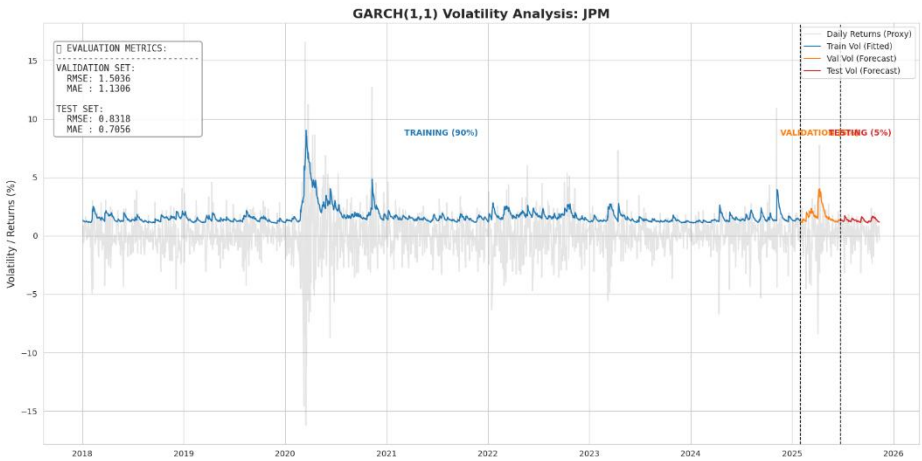

Fig. 2. Volatility Forecast của GARCH(1,1) JPM

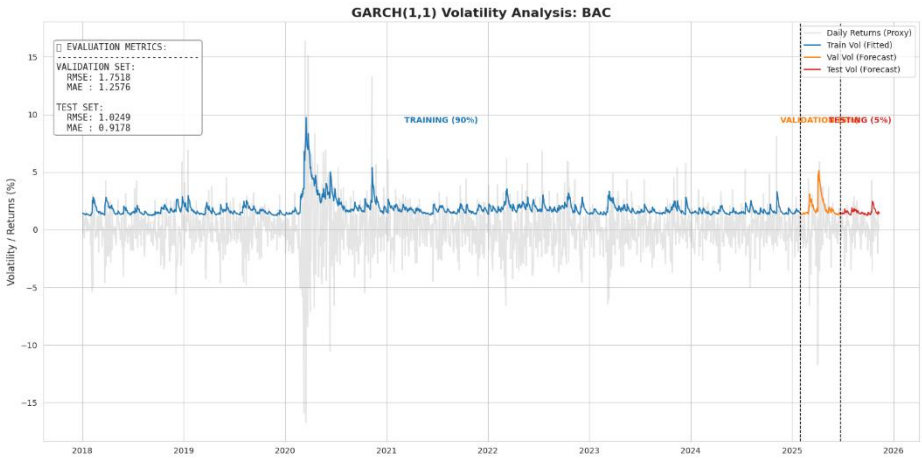

Fig. 3. Volatility Forecast của GARCH(1,1) BAC

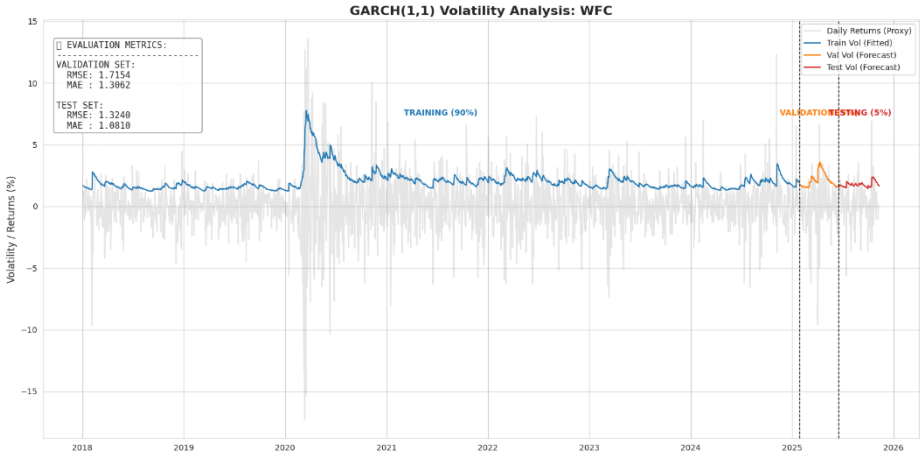

Fig. 4. Volatility Forecast của GARCH(1,1) WFC

4.3 Results of Machine Learning Models

So sánh Logistic Regression và SVM

. Logistic Regression được sử dụng như mô hình baseline cho bài toán phân loại hướng biến động giá. Trên cả ba cổ phiếu, mô hình cho độ chính xác xấp xỉ mức ngẫu nhiên, phản ánh hạn chế của giả định tuyến tính trong việc mô hình hóa động lực ngắn hạn của thị trường.

SVM với kernel RBF cho kết quả cải thiện hơn Logistic Regression, nhờ khả năng học các ranh giới phi tuyến trong không gian đặc trưng. Việc áp dụng SMOTE trên tập huấn luyện giúp giảm ảnh hưởng của mất cân bằng lớp, từ đó nâng cao F1-score trung bình, đặc biệt đối với JPM và WFC.

Table 3. Accuracy và F1-score của Logistic Regression và SVM

Model	Bank	Accuracy	F1-score (macro)
Logistic Regression	JPM	0.50	0.50
	BAC	0.49	0.40
	WFC	0.49	0.37
SVM (RBF + SMOTE)	JPM	0.5370	0.4831

	BAC	0.4671	0.4430
	WFC	0.5031	0.4527

Kết quả này cho thấy, mặc dù SVM cải thiện so với Logistic Regression nhờ khả năng mô hình hóa phi tuyến, cả hai mô hình phân loại vẫn chịu hạn chế đáng kể do mức độ nhiễu cao và tính khó dự đoán vốn có của chuyển động giá ngắn hạn.

Mô hình bổ sung: Gradient Boosting Tree (LightGBM)

. Gradient Boosting Tree, được triển khai bằng LightGBM, tập trung vào bài toán dự báo realized volatility ngày kế tiếp. Do khác biệt về biến mục tiêu, mô hình này không được so sánh trực tiếp với các mô hình dự báo giá hoặc phân loại hướng biến động.

Kết quả cho thấy LightGBM đạt sai số thấp và ổn định trên cả ba cổ phiếu. Phân tích SHAP chỉ ra rằng các đặc trưng có mức đóng góp cao nhất bao gồm biến động trễ, lợi suất trễ và các chỉ số thị trường chung như SPX500 và VIX, trong khi sentiment thể hiện mức độ ảnh hưởng khác nhau giữa các cổ phiếu.

Table 4. RMSE và MAE của LightGBM cho JPM, BAC, WFC

Bank	RMSE	MAE
JPM	0.1982	0.1205
BAC	0.2074	0.1343
WFC	0.2312	0.1515

Bar Plot

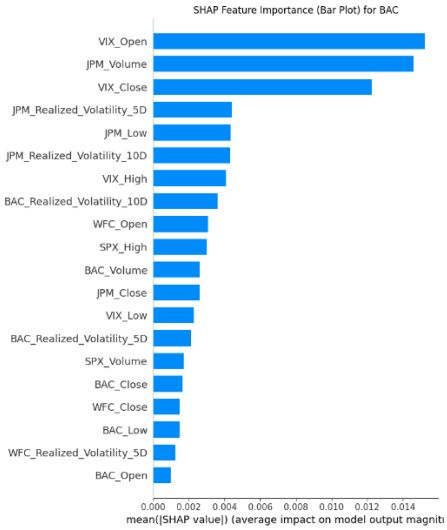

Dot Plot

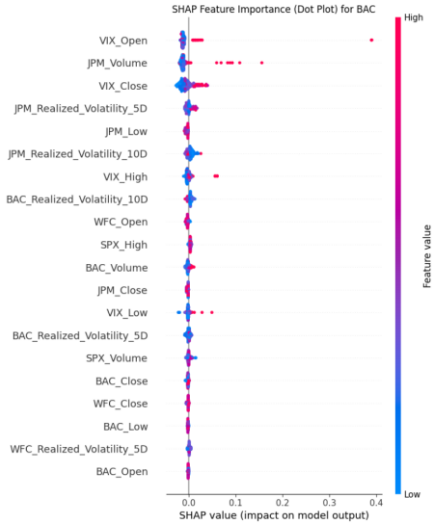

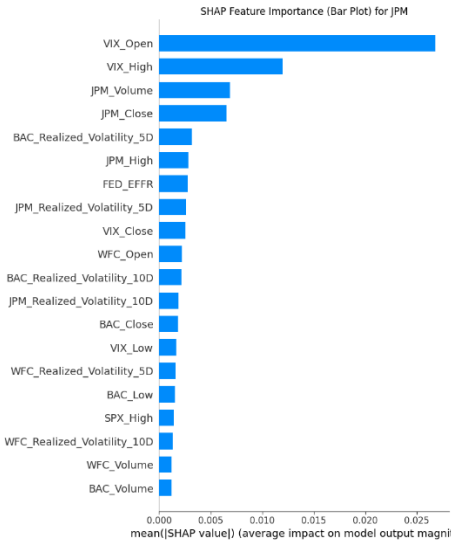

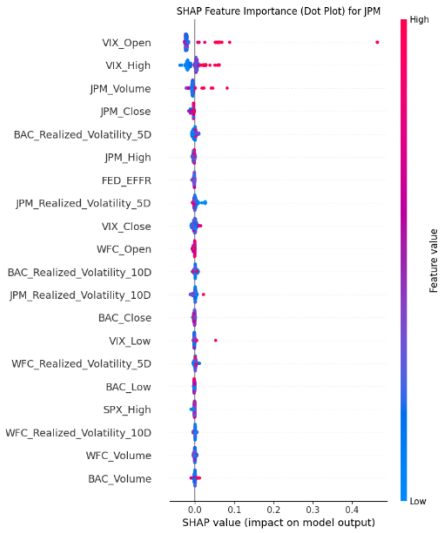

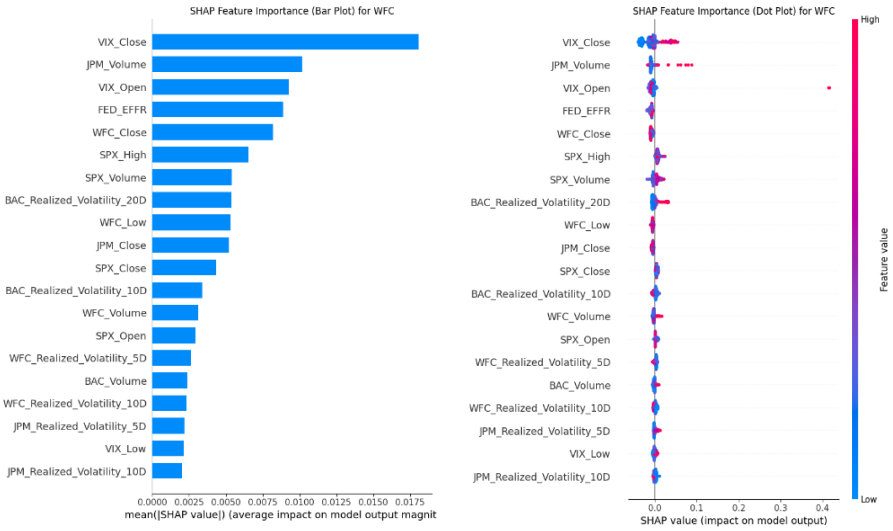

Fig. 5. SHAP Summary Plot cho từng cổ phiếu

4.4 Results of Deep Learning Models

So sánh LSTM có sentiment và LSTM không sentiment.

. Hai biến thể của LSTM được xây dựng với kiến trúc tương đương, khác biệt duy nhất nằm ở việc có hoặc không tích hợp chỉ số sentiment. Kết quả cho thấy việc bổ sung sentiment mang lại cải thiện rõ rệt đối với WFC, trong khi mức cải thiện đối với JPM và BAC tương đối hạn chế.

Điều này cho thấy mức độ nhạy cảm với thông tin và tâm lý thị trường của WFC cao hơn so với hai ngân hàng còn lại, qua đó khẳng định vai trò của sentiment trong các mô hình dự báo giá đối với những cổ phiếu có độ nhiễu lớn.

Table 5. RMSE và MAPE của LSTM (with sentiment) và LSTM (no sentiment)

Bank	Model	RMSE (Test)	MAPE (Test)
BAC	LSTM + Sentiment	5.0045	9.25%
	LSTM (No Sentiment)	6.5127	13.37%
JPM	LSTM + Sentiment	41.4183	10.82%

	LSTM (No Sentiment)	12.9289	3.99%
WFC	LSTM + Sentiment	23.2025	26.61%
	LSTM (No Sentiment)	3.2752	3.38%

LSTM (with sentiment) **LSTM (no sentiment)**

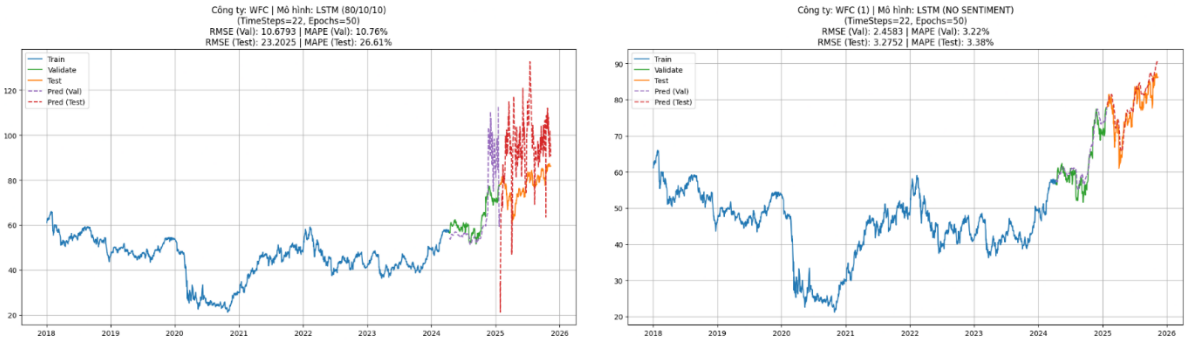

Fig. 6. Mô hình LSTM (with sentiment) và LSTM (no sentiment) từng cổ phiếu

Dựa trên phân tích sâu về dữ liệu, việc tích hợp Sentiment thất bại chủ yếu do 3 vấn đề cốt lõi của bộ dữ liệu hành vi:

- Sự khập khiễng về thời gian (Date Mismatch). Dữ liệu giá có từ 2018, nhưng Sentiment chỉ xuất hiện từ 05/2022. Trong 4 năm đầu, mô hình học với giá trị Sentiment = 0 (fillna), hình thành quy luật "Sentiment không quan trọng". Khi sang giai đoạn Test (sau 2022), sự xuất hiện đột ngột của Sentiment khiến mô hình bị "sốc" và dự báo sai lệch.
- Dữ liệu thưa thớt tạo "Gai nhọn" (Impulse Noise), Sentiment không liên tục (có 1 ngày, mất 5-6 ngày). Việc tín hiệu giật cục từ 0 vọt lên cao rồi rớt xuống 0 tạo ra các kích thích dạng xung (impulse), khiến LSTM nhảy số loạn xạ (răng cưa) thay vì dự báo xu hướng mượt mà.
- Thang đo "khổng lồ" (Scale Explosion). Giá trị Sentiment quá lớn (lên tới hàng trăm triệu) so với biên độ nhỏ của giá chứng khoán. Khi chuẩn hóa (Scaling), các ngày không có tin tức (giá trị 0) bị nén chặt, trong khi các ngày có tin tức trở thành những cực trị ngoại lai, phá vỡ cấu trúc học của mạng nơ-ron.

So sánh LSTM (with sentiment) và GRU

. GRU và LSTM (with sentiment) đều được sử dụng cho bài toán dự báo giá đóng cửa ngày kế tiếp, với chiến lược chia dữ liệu và chuẩn hóa tương đồng. GRU cho kết quả ổn định và hội tụ nhanh hơn nhờ cấu trúc gọn nhẹ, đặc biệt phù hợp với các chuỗi thời gian có độ dài vừa phải.

Tuy nhiên, LSTM tích hợp sentiment đạt sai số thấp hơn trong các giai đoạn thị trường biến động mạnh, đặc biệt đối với WFC. Điều này cho thấy LSTM có khả năng khai thác tốt hơn các tín hiệu hành vi và phụ thuộc dài hạn khi được cung cấp thông tin sentiment.

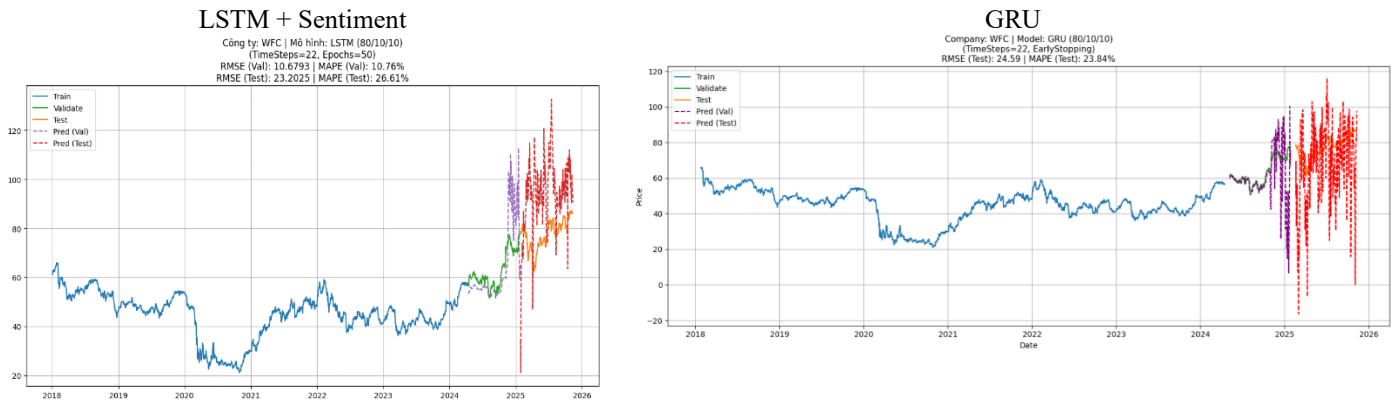

Fig. 7. Actual vs Prediction cho WFC: GRU và LSTM + Sentiment

4.5 Per-Stock Insights

Phân tích theo từng cổ phiếu cho thấy sự khác biệt rõ rệt về đặc tính dữ liệu và mức độ dự báo. JPM là cổ phiếu có tính ổn định cao nhất, với sai số dự báo thấp trên hầu hết các mô hình. BAC phản ứng mạnh với các biến vĩ mô, khiến các mô hình phi tuyến như SVM và LSTM thể hiện ưu thế rõ rệt. Ngược lại, WFC là cổ phiếu khó dự báo nhất; chỉ các mô hình tích hợp sentiment, đặc biệt là LSTM, mới duy trì được hiệu năng ổn định.

4.6 Summary of Findings

Kết quả thực nghiệm cho thấy không tồn tại một mô hình duy nhất vượt trội trong mọi bối cảnh. ARIMAX và SARIMAX phù hợp cho phân tích cấu trúc tuyến tính và ảnh hưởng vĩ mô, trong đó SARIMAX cho hiệu năng ổn định hơn. Trong nhóm học máy, SVM cải thiện so với Logistic Regression nhưng vẫn bị hạn chế bởi nhiễu dữ liệu. Các mô hình học sâu, đặc biệt là LSTM tích hợp sentiment, đạt hiệu năng cao nhất trong dự báo giá ngắn hạn, nhất là đối với các cổ phiếu nhạy cảm với thông tin như WFC.

Những khác biệt này nhấn mạnh tầm quan trọng của việc lựa chọn mô hình phù hợp với mục tiêu dự báo và đặc trưng dữ liệu, thay vì tìm kiếm một phương pháp tối ưu chung cho mọi bối cảnh.

5 Discussion

Kết quả thực nghiệm cho thấy hiệu năng dự báo của các mô hình phụ thuộc mạnh vào mục tiêu dự báo và đặc tính cấu trúc của từng cổ phiếu, thay vì chỉ phụ thuộc vào độ phức tạp của mô hình. Trong nhóm mô hình kinh tế lượng, ARIMAX và SARIMAX tiếp tục thể hiện giá trị trong việc mô hình hóa mối quan hệ tuyến tính giữa giá cổ phiếu và các yếu tố vĩ mô. Việc tích hợp các biến ngoại sinh giúp hai mô hình này phản ứng tốt hơn với các cú sốc kinh tế, tuy nhiên giả định dừng và cấu trúc tuyến tính vẫn giới

hạn khả năng thích nghi trong các giai đoạn biến động mạnh hoặc khi xuất hiện hành vi phi tuyến, phù hợp với các nhận định trong văn liệu tài chính gần đây [1,2]

So sánh ARIMAX và SARIMAX cho thấy vai trò quan trọng của thành phần mùa vụ trong dữ liệu tài chính. SARIMAX đạt hiệu năng ổn định hơn trên các cổ phiếu có dấu hiệu chu kỳ rõ rệt, trong khi ARIMAX vẫn cho kết quả cạnh tranh trong những trường hợp cấu trúc dữ liệu tương đối ổn định. Điều này củng cố quan điểm rằng các mô hình kinh tế lượng truyền thống vẫn có giá trị thực tiễn, đặc biệt trong bối cảnh cần khả năng diễn giải và kiểm định giả thuyết kinh tế [8].

Đối với bài toán phân loại hướng biến động giá, cả Logistic Regression và SVM đều cho thấy hiệu năng hạn chế, phản ánh tính khó dự đoán vốn có của chuyển động giá ngắn hạn. Mặc dù SVM cải thiện so với Logistic Regression nhờ khả năng mô hình hóa phi tuyến và xử lý mất cân bằng lớp bằng SMOTE, mức cải thiện vẫn tương đối khiêm tốn. Kết quả này phù hợp với nhiều nghiên cứu chỉ ra rằng tín hiệu dự báo hướng giá ở tần suất ngày thường bị chi phối mạnh bởi nhiễu và các yếu tố ngẫu nhiên [6].

Trong nhóm học sâu, kết quả cho thấy vai trò của sentiment không mang tính phổ quát mà phụ thuộc vào đặc tính của từng tài sản. Việc tích hợp sentiment không luôn cải thiện sai số dự báo giá, thậm chí trong một số trường hợp còn làm gia tăng RMSE, cho thấy sentiment có thể đưa thêm nhiễu vào mô hình nếu không gắn với hành vi thị trường cụ thể. Tuy nhiên, đối với các cổ phiếu có mức độ nhạy cảm cao với thông tin và tâm lý nhà đầu tư như WFC, sentiment mang lại giá trị bổ sung rõ rệt, đặc biệt trong các giai đoạn thị trường biến động mạnh. Kết quả này phù hợp với các nghiên cứu trước đó về vai trò của thông tin văn bản và tâm lý thị trường trong dự báo tài chính [6,7].

So sánh giữa GRU và LSTM cho thấy sự đánh đổi giữa độ phức tạp mô hình và khả năng khai thác phụ thuộc dài hạn. GRU với cấu trúc gọn nhẹ mang lại quá trình huấn luyện ổn định và hội tụ nhanh, phù hợp cho dự báo ngắn hạn khi dữ liệu hạn chế. Ngược lại, LSTM, đặc biệt khi tích hợp sentiment, thể hiện ưu thế trong việc nắm bắt các tín hiệu hành vi và phụ thuộc dài hạn, dù phải đánh đổi bằng độ phức tạp cao hơn và nguy cơ overfitting nếu dữ liệu không đủ phong phú, phù hợp với các phân tích trong lĩnh vực học sâu cho chuỗi thời gian tài chính [2,9]

Cuối cùng, các mô hình dự báo biến động như GARCH(1,1) và Gradient Boosting Tree đóng vai trò bổ trợ quan trọng trong khung phân tích tổng thể. GARCH giúp làm rõ động lực biến động có điều kiện của lợi suất và hiện tượng volatility clustering, trong khi LightGBM cung cấp một cách tiếp cận linh hoạt và có khả năng giải thích thông qua SHAP đối với các yếu tố chi phối mức độ biến động thị trường [11]. Việc kết hợp các mô hình dự báo giá và mô hình dự báo biến động cho phép xây dựng một góc nhìn toàn diện hơn về hành vi cổ phiếu ngân hàng, thay vì chỉ tập trung vào độ chính xác dự báo giá đơn thuần [3].

Nhìn chung, các kết quả nhấn mạnh rằng lựa chọn mô hình dự báo cần được điều chỉnh theo từng mục tiêu cụ thể và đặc trưng của từng tài sản, thay vì tìm kiếm một phương pháp tối ưu chung cho mọi bối cảnh.

6 Conclusion

Nghiên cứu này đã xây dựng và đánh giá một khung thực nghiệm có hệ thống nhằm phân tích hành vi và biến động giá cổ phiếu ngân hàng Hoa Kỳ trong giai đoạn 2018–2025, dựa trên dữ liệu đa nguồn bao gồm giá cổ phiếu, các yếu tố kinh tế vĩ mô và chỉ số sentiment. Thông qua việc triển khai và so sánh các mô hình thuộc ba nhóm phương pháp chính—kinh tế lượng, học máy và học sâu—nghiên cứu cung cấp một cái nhìn toàn diện về hiệu năng dự báo trong các bối cảnh và mục tiêu khác nhau, đồng thời làm rõ những đánh đổi phương pháp giữa khả năng diễn giải, tính linh hoạt và độ chính xác dự báo.

Kết quả thực nghiệm cho thấy không tồn tại một mô hình duy nhất vượt trội cho mọi cổ phiếu và mọi nhiệm vụ dự báo. Các mô hình kinh tế lượng tiếp tục thể hiện giá trị trong việc mô hình hóa cấu trúc tuyến tính và tác động của các yếu tố vĩ mô, đặc biệt khi dữ liệu thể hiện tính chu kỳ rõ rệt. Trong khi đó, các phương pháp học máy và học sâu cho thấy lợi thế trong việc nắm bắt các quan hệ phi tuyến và động lực theo thời gian, nhưng hiệu năng của chúng phụ thuộc mạnh vào đặc tính dữ liệu, chiến lược tiền xử lý và phương pháp validation. Những kết quả này nhấn mạnh rằng độ phức tạp của mô hình không đồng nghĩa với hiệu năng dự báo vượt trội trong mọi trường hợp.

Một phát hiện quan trọng của nghiên cứu là vai trò của sentiment không mang tính phổ quát. Việc tích hợp sentiment chỉ mang lại cải thiện trong những bối cảnh dữ liệu và hành vi thị trường cụ thể, trong khi ở các trường hợp khác, sentiment có thể làm gia tăng nhiễu và suy giảm hiệu năng dự báo. Điều này cho thấy các tín hiệu hành vi cần được xử lý và tích hợp một cách thận trọng, đặc biệt trong các mô hình học sâu nhạy cảm với cấu trúc và thang đo dữ liệu.

Nhìn chung, nghiên cứu khẳng định tầm quan trọng của việc lựa chọn mô hình phù hợp với mục tiêu dự báo và đặc trưng dữ liệu cụ thể, thay vì tìm kiếm một phương pháp tối ưu chung. Trong tương lai, khung nghiên cứu này có thể được mở rộng bằng cách khai thác dữ liệu tần số cao, cải thiện cách biểu diễn sentiment theo thời gian, hoặc tích hợp các kiến trúc học sâu tiên tiến hơn nhằm nâng cao khả năng tổng quát hóa và tính ứng dụng trong các bài toán dự báo tài chính thực tế.

References

1. Gu, S., Kelly, B., Xiu, D.: Empirical asset pricing via machine learning. Review of Financial Studies 33, 2223–2273 (2020).
   https://doi.org/10.1093/rfs/hhaa009
2. Lim, B., Zohren, S.: Time-series forecasting with deep learning: A survey. Philosophical Transactions of the Royal Society A 379, 20200209 (2021).
   https://doi.org/10.1098/rsta.2020.0209
3. Engle, R.: GARCH 101: The use of ARCH/GARCH models in applied econometrics. *Journal of Economic Perspectives* **15**, 157–168 (2001).
   https://doi.org/10.1257/jep.15.4.157
4. Wang, P.-C., Hoai, T.: Stock price prediction based on dual important indicators using ARIMAX: A case study in Vietnam. *Journal of Intelligent Systems* **34** (2025).
   https://doi.org/10.1515/jisys-2024-0101

5. Parker, M., Ghahremani, M., Shiaeles, S.: Stock price prediction using a stacked heterogeneous ensemble. *International Journal of Financial Studies* **13**, 201 (2025). https://doi.org/10.3390/ijfs13040201
6. Bollen, J., Mao, H., Zeng, X.: Twitter mood predicts the stock market. *Journal of Computational Science* **2**, 1–8 (2011). https://doi.org/10.1016/j.jocs.2010.12.007
7. Baker, M., Wurgler, J.: Investor sentiment in the stock market. *Journal of Economic Perspectives* **21**, 129–152 (2007). https://doi.org/10.1257/jep.21.2.129
8. Tsay, R.S.: *Analysis of Financial Time Series*. 3rd edn. Wiley, Hoboken (2010).
9. Hochreiter, S., Schmidhuber, J.: Long short-term memory. *Neural Computation* **9**(8), 1735–1780 (1997).
10. Chawla, N.V., Bowyer, K.W., Hall, L.O., Kegelmeyer, W.P.: SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research* **16**, 321–357 (2002).
11. Lundberg, S., Lee, S.-I.: A unified approach to interpreting model predictions. In: *Advances in Neural Information Processing Systems (NeurIPS)*, pp. 4765–4774 (2017).